KAIST Include 동아리 스터디

# AlphaGo와 AlphaGo Zero를 만들며 익히는 딥러닝 및 강화학습

Chris Ohk
utilForever@gmail.com

# 들어가며



- 인공 신경망 (Artificial Neural Network; ANN)

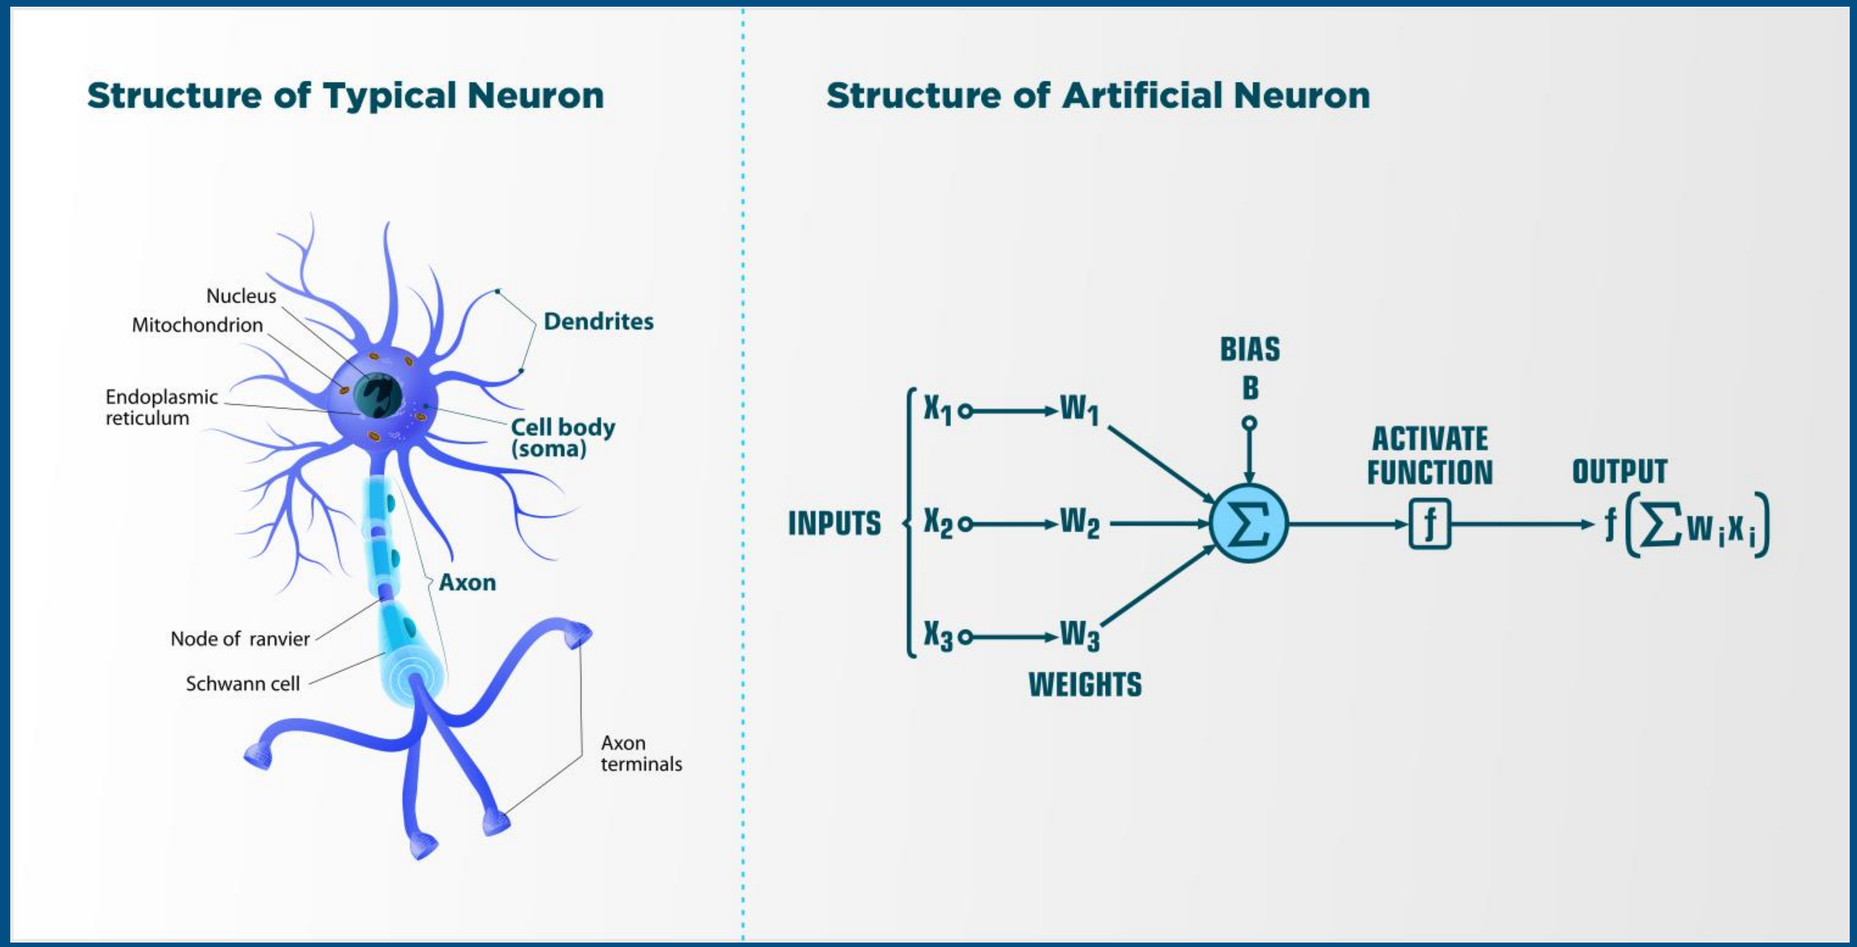


https://analysts.com/blogs/fundamentals-artificial-neural-networks-are-to-deep-learning-what-atoms-are-to-matter

# 손글씨 숫자 분류



- numpy
  - 머신러닝 및 수학 컴퓨팅 관련 산업 전반의 Python 표준 라이브러리
  - 설치 방법

    1) pip를 사용하는 경우

    ```
    pip install numpy
    ```

    2) Conda를 사용하는 경우

    ```
    conda install numpy
    ```

# 손글씨 숫자 분류



- MNIST 숫자 손글씨 데이터셋

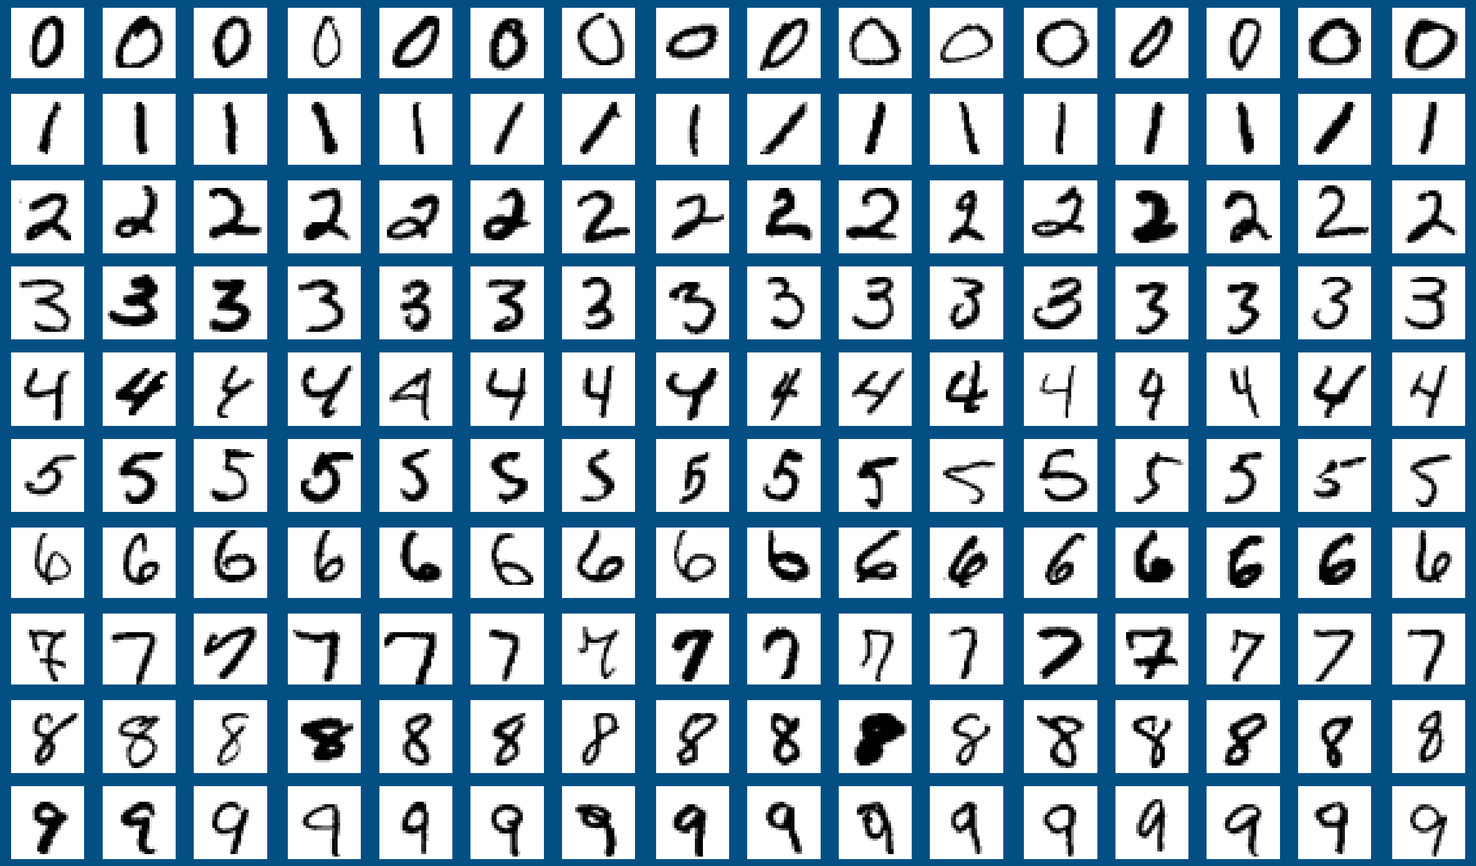

https://ko.wikipedia.org/wiki/MNIST_%EB%8D%B0%EC%9D%B4%ED%84%B0%EB%B2%A0%EC%9D%B4%EC%8A%A4

# 손글씨 숫자 분류



- MNIST 데이터 처리
  - MNIST 라벨의 원-핫 인코딩

```
import six.moves.cPickle as pickle
import gzip
import numpy as np

def encode_label(j):
  e = np.zeros((10, 1))
  e[j] = 1.0
  return e
```

# 손글씨 숫자 분류



- 원-핫 인코딩 (One-Hot Encoding)

Label Encoding

| Food Name | Categorical # | Calories |
|---|---|---|
| Apple | 1 | 95 |
| Chicken | 2 | 231 |
| Broccoli | 3 | 50 |

→

One Hot Encoding

| Apple | Chicken | Broccoli | Calories |
|---|---|---|---|
| 1 | 0 | 0 | 95 |
| 0 | 1 | 0 | 231 |
| 0 | 0 | 1 | 50 |

https://medium.com/@michaeldelsole/what-is-one-hot-encoding-and-how-to-do-it-f0ae272f1179

# 손글씨 숫자 분류



- MNIST 데이터 처리
  - MNIST 데이터 형태 변형 및 훈련 데이터와 검정 데이터 불러오기
    (MNIST 데이터셋의 이미지는 가로/세로 28픽셀) → $28 \times 28 = 784$ 크기의 특징 벡터

```
def shape_data(data):
  features = [np.reshape(x, (784, 1)) for x in data[0]]

  labels = [encode_label(y) for y in data[1]]

  return zip(features, labels)

def load_data():
  with gzip.open('mnist.pkl.gz', 'rb') as f:
    train_data, validation_data, test_data = pickle.load(f)

  return shape_data(train_data), shape_data(test_data)
```

# 손글씨 숫자 분류



- MNIST 데이터 처리
  - 동일한 수를 나타내는 이미지의 평균값 구하기
    (손글씨 숫자를 인식하는 방법의 중요한 열쇠 중 하나 = 패턴 인식)

```python
import numpy as np
from dlgo.nn.load_mnist import load_data
from dlgo.nn.layers import sigmoid_double

def average_digit(data, digit):
  filtered_data = [x[0] for x in data if np.argmax(x[1]) == digit]
  filtered_array = np.asarray(filtered_data)
  return np.average(filtered_array, axis=0)

train, test = load_data()
avg_eight = average_digit(train, 8)
```

# 손글씨 숫자 분류



- 훈련 데이터셋에서의 평균 8

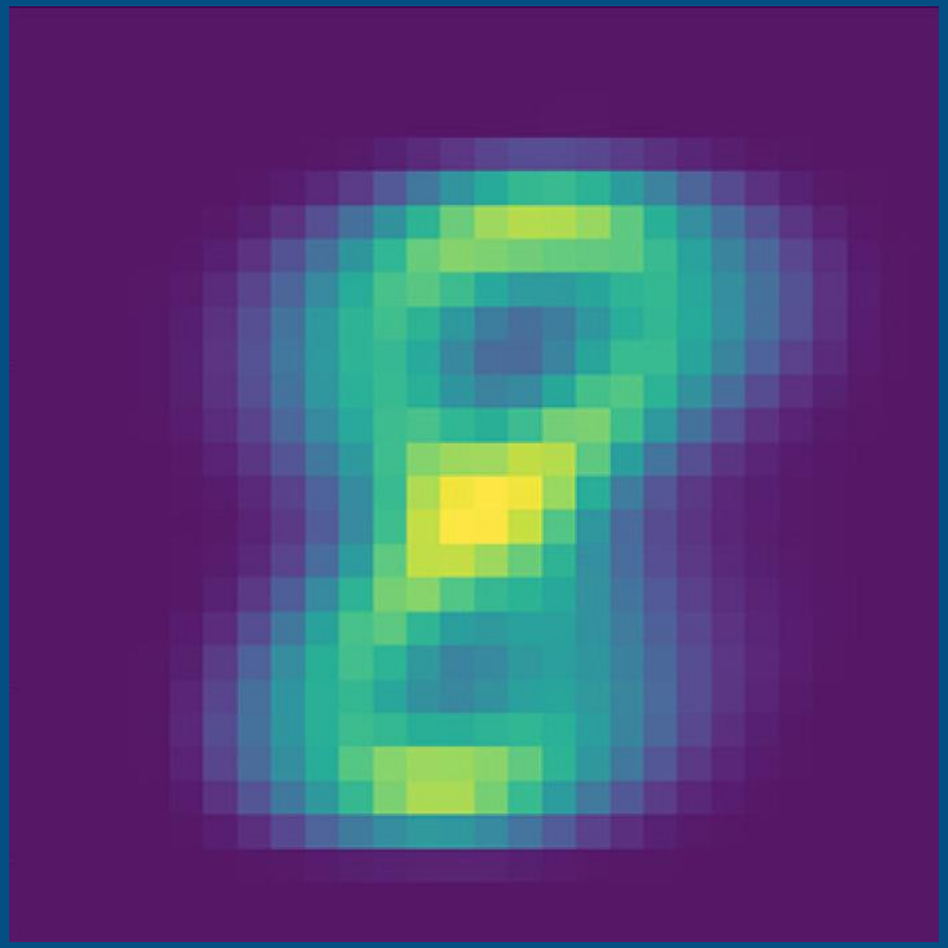

# 손글씨 숫자 분류



- MNIST 데이터 처리
  - 훈련 데이터셋에서 8인 이미지의 평균을 구하고 출력하기
    (avg_eight : 파라미터 → 신경망에서는 이를 **가중치(Weight)**로 사용할 수 있다.)

```
from matplotlib import pyplot as plt

img = (np.reshape(avg_eight, (28, 28)))
plt.imgshow(img)
plt.show()
```

# 손글씨 숫자 분류



- MNIST 데이터 처리
  - 내적을 사용해 숫자가 가중치에 얼마나 가까운지 계산하기
    → 내적의 출력을 $[0, 1]$ 범위로 변환하려면 어떻게 해야 할까?

```
x_3 = train[2][0]
x_18 = train[17][0]

W = np.transpose(avg_eight)
np.dot(W, x_3)
np.dot(W, x_18)
```

# 손글씨 숫자 분류



- MNIST 데이터 처리
  - **시그모이드 함수 (Sigmoid Function)** : $\sigma(x) = \frac{1}{1+e^{-x}}$

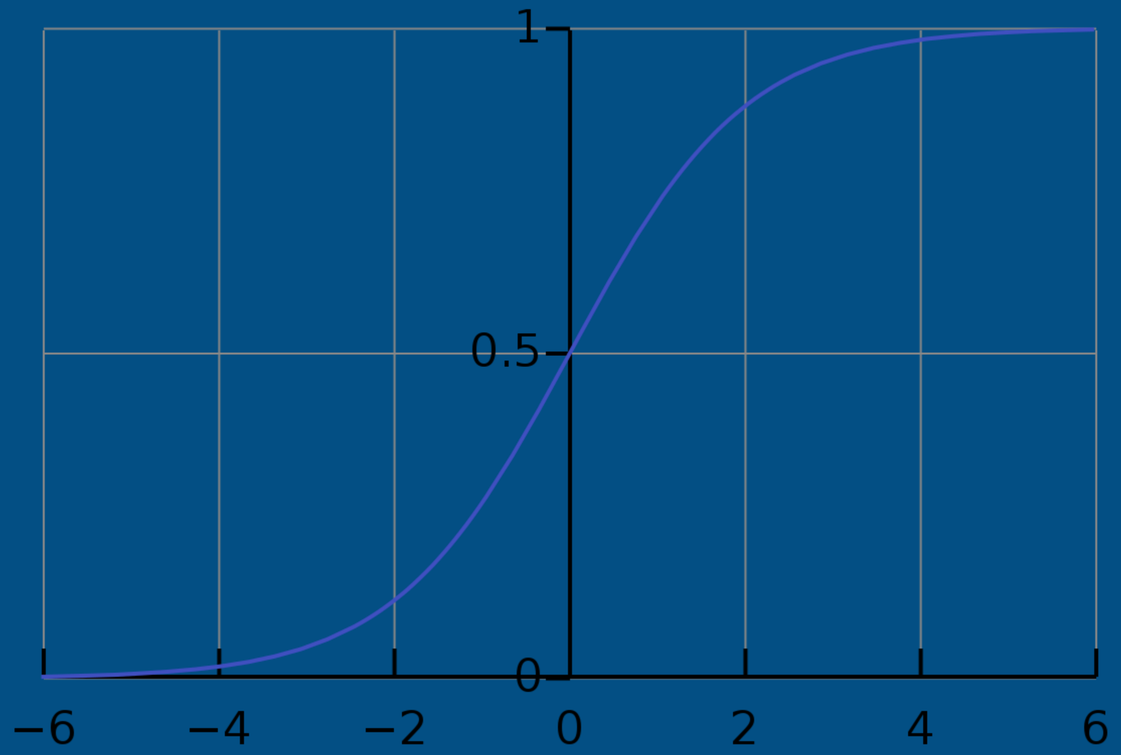


https://en.wikipedia.org/wiki/Sigmoid_function

# 손글씨 숫자 분류



- MNIST 데이터 처리
  - double 값과 벡터에 대한 간단한 시그모이드 함수 구현

```
def sigmoid_double(x):
  return 1.0 / (1.0 + np.exp(-x))

def sigmoid(z):
  return np.vectorize(sigmoid_double)(z)
```

# 손글씨 숫자 분류



- MNIST 데이터 처리
  - 시그모이드 함수를 사용해 적용해도 문제가 있다. 예를 들어, `sigmoid(54.2)`와 `sigmoid(20.1)`은 실제로 구분하기 어렵다. 이 문제를 어떻게 해결해야 할까?
  - 내적값의 결과를 0 부근으로 옮기는 방식으로 해결할 수 있다.
    보통 $b$로 나타내는 수치인 **편향치(Bias)**를 추가한다.

# 손글씨 숫자 분류



- MNIST 데이터 처리
  - 시그모이드와 내적을 적용해서 가중치와 편향치로부터 예측값 구하기

```
def predict(x, W, b):
  return sigmoid_double(np.dot(W, x) + b)

b = -45

print(predict(x_3, W, b))
print(predict(x_18, W, b))
```

# 손글씨 숫자 분류



- MNIST 데이터 처리
  - 로지스틱 회귀 (Logistic Regression)

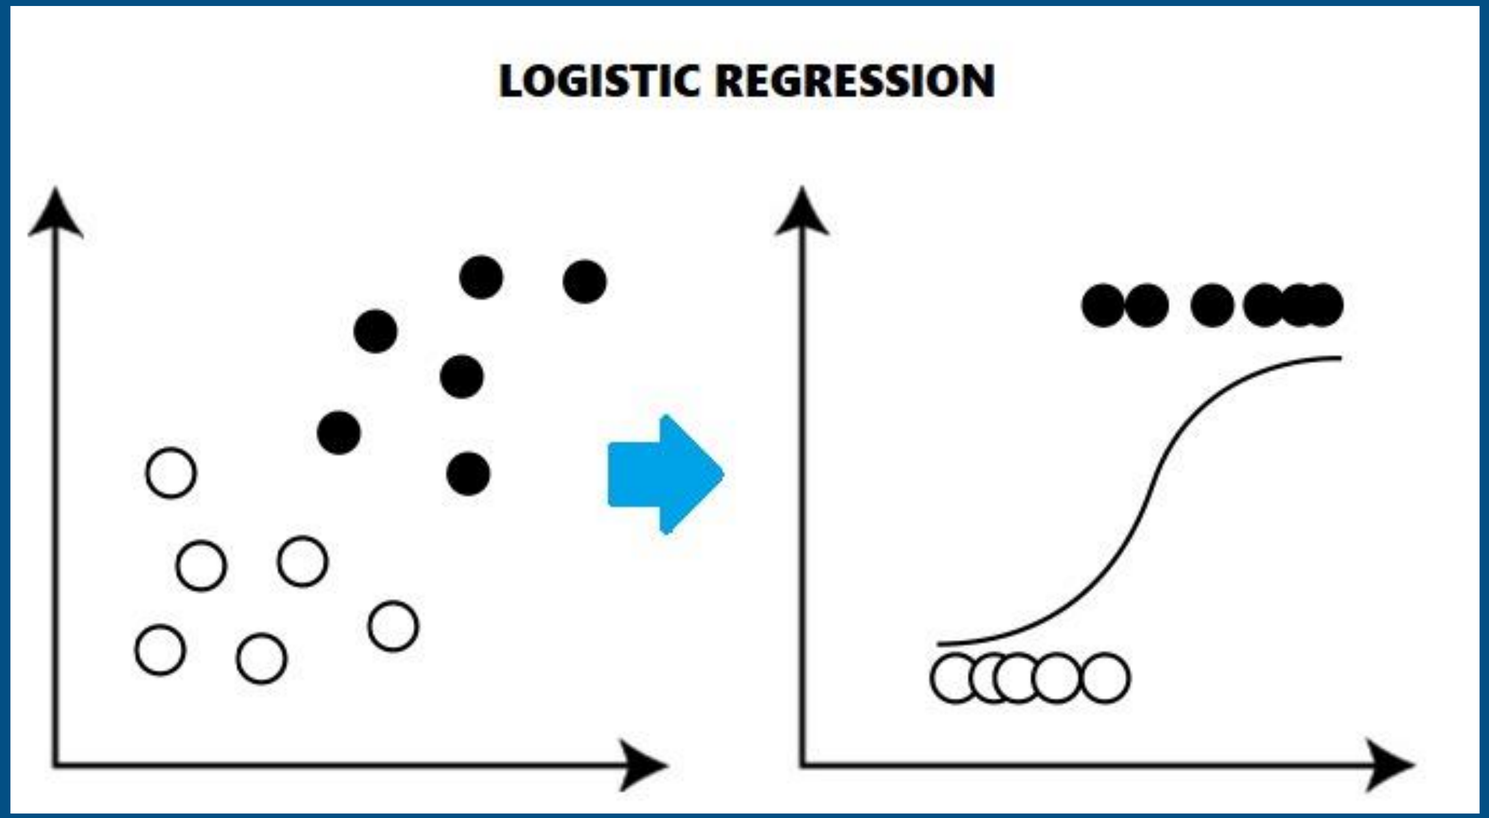


https://www.equiskill.com/understanding-logistic-regression/

# 손글씨 숫자 분류



- MNIST 데이터 처리
  - 로지스틱 회귀 (Logistic Regression)

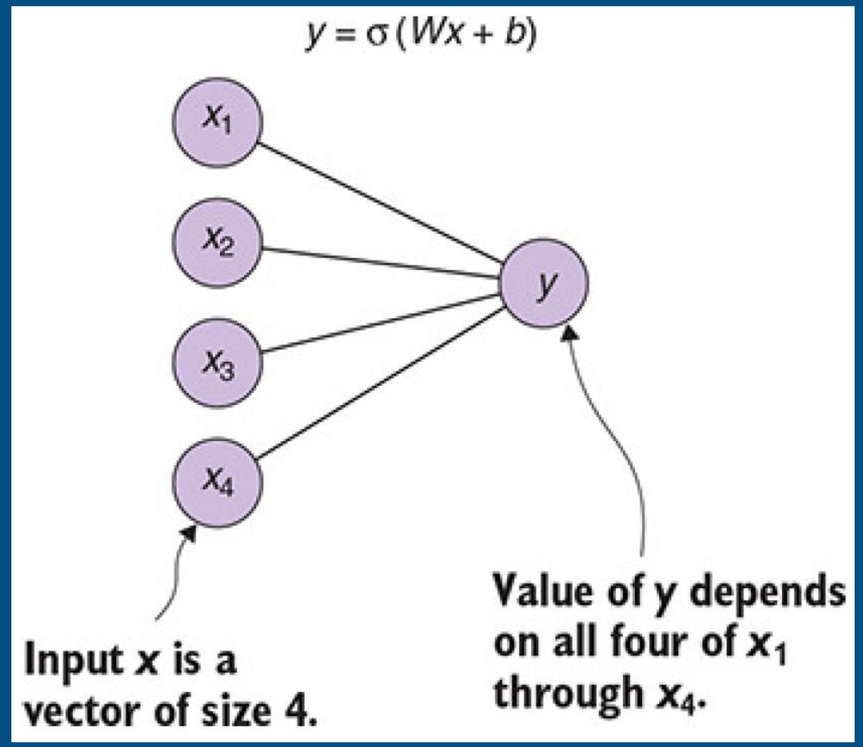

# 손글씨 숫자 분류



- MNIST 데이터 처리
  - 결정 임계치를 사용한 모델 예측값 평가

```
def evaluate(data, digit, threshold, W, b):
  total_samples = 1.0 * len(data)
  correct_predictions = 0
  for x in data:
    if predict(x[0], W, b) > threshold and np.argmax(x[1]) == digit:
      correct_predictions += 1
    if predict(x[0], W, b) <= threshold and np.argmax(x[1]) != digit:
      correct_predictions += 1
  return correct_predictions / total_samples
```

# 손글씨 숫자 분류



- MNIST 데이터 처리
  - 세 데이터셋의 예측 정확도 구하기

```
evaluate(data=train, digit=8, threshold=0.5, W=W, b=b)

evaluate(data=test, digit=8, threshold=0.5, W=W, b=b)

eight_test = [x for x in test if np.argmax(x[1]) == 8]
evaluate(data=eight_test, digit=8, threshold=0.5, W=W, b=b)
```

# 손글씨 숫자 분류



- 지금까지의 과정에서 무엇이 잘못되었고, 무엇을 개선할 수 있을까?
  - 이 모델은 특정 숫자(8)만 구분할 수 있다. 훈련 데이터셋과 검정 데이터셋에서 8은 10% 뿐이다. → **10가지 숫자 모두를 정확하게 예측하는 모델을 만들어야 한다.**
  - 모델에 들어가는 파라미터가 작다. → **데이터의 다양성을 잡아낼 수 있도록 훨씬 더 많은 파라미터를 효과적으로 사용하는 알고리즘을 찾아야 한다.**
  - 주어진 예측에서는 숫자가 8이냐 8이 아니냐를 결정하는 기준값을 선택하는 것 뿐이다. → **예측값이 실제 결과와 얼마나 가까운지에 대한 개념을 공식화해야 한다.**
  - 모델의 파라미터를 만들 때 직감에 따라 값을 직접 조정했다. → **훈련 데이터에 대해 얼마나 잘 예측하는지에 따라 모델의 파라미터를 갱신하는 절차를 마련해야 한다.**

# 신경망 기초



- 단순한 인공 신경망으로의 로지스틱 회귀
  - 앞에서 우리는 **이항 분류**에 로지스틱 회귀를 사용했다.
    샘플 데이터를 나타내는 특징 벡터 $x$를 가져와서 여기에 가중치 행렬 $W$를 곱한 후 편향치 $b$를 더하는 알고리즘에 넣어준다. 그리고 예측값 $y$를 0과 1 사이로 나타내서 마무리하기 위해 이 값에 시그모이드 함수 $y = \sigma(Wx + b)$를 취한다.
  - 특징 벡터 $x$는 **유닛**이라고도 하는 뉴런 집합으로 해석할 수 있다. 이 유닛은 $W$와 $b$의 값에 의해 변경되어 $y$로 연결된다. 이어서 활성화 함수로 시그모이드 함수를 사용해 $Wx + b$의 결과를 $[0, 1]$ 범위에 대응시킨다. 만약 이 값이 1에 가깝다면 뉴런 $y$를 활성화하고, 0에 가깝다면 비활성화한다.

# 신경망 기초



- 1차원 이상의 결과를 갖는 신경망
  - 앞에서 손글씨 숫자 인식 문제를 8과 나머지 숫자로 분류하는 이항 분류로 단순화했다. 하지만 각 숫자를 예측해보고 싶을 것이다. 이제 모델을 수정해 보자.
  - 우선 길이 10의 결과 벡터 $y$를 만든다. ($y$는 각 숫자별 가능도를 나타내는 값을 갖는다.)

$$y = \begin{bmatrix} y_0 \\ y_1 \\ \cdots \\ y_8 \\ y_9 \end{bmatrix}$$

# 신경망 기초



- 1차원 이상의 결과를 갖는 신경망
  - 다음으로 가중치와 편향치를 변경한다. ($W$는 원래 길이 784의 벡터였다.)
    여기서는 $W$를 (10, 784) 차원의 행렬로 만든다. 그러면 $W$와 입력 벡터 $x$의 행렬곱 $Wx$로 길이 10의 벡터를 구할 수 있다. 여기에 길이 10인 벡터로 편향치를 만들면 이를 $Wx$에 더할 수 있다. 마지막으로 벡터 $z$를 각 값에 적용해 시그모이드를 계산할 수 있다.

$$\sigma(z) = \begin{bmatrix} \sigma(z_0) \\ \sigma(z_1) \\ \dots \\ \sigma(z_8) \\ \sigma(z_9) \end{bmatrix}$$

# 신경망 기초



- 1차원 이상의 결과를 갖는 신경망
  - 순방향 신경망 (Feed-Forward Network)

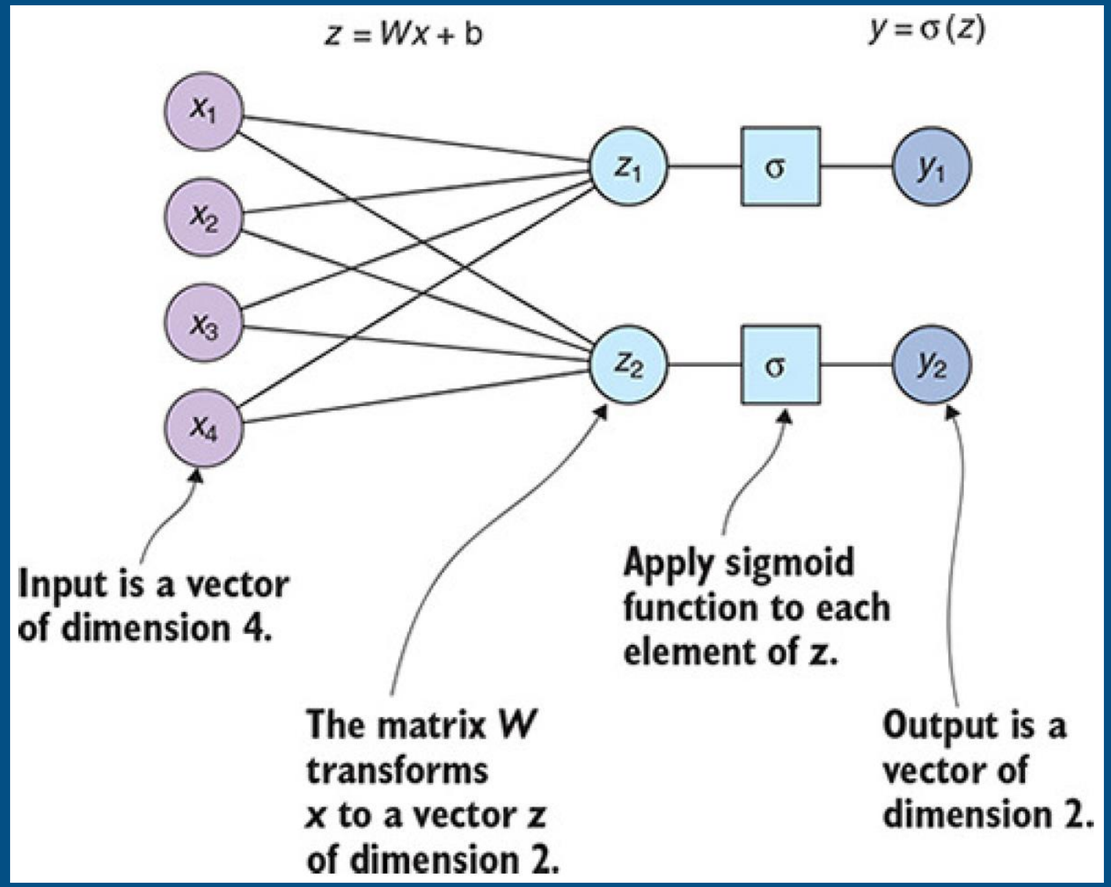

# 순방향 신경망



- 앞에서 설명했던 내용을 짧게 정리해보자.
  1. 입력 뉴런 $x$에 $z = Wx + b$ 형식으로 간단한 변형을 취한다. 선형대수학 용어로 이런 변형을 **아핀 선형 변환(Affine-Linear Transformation)**이라고 한다. 여기서는 과정을 쉽게 따라갈 수 있게 $z$라는 중간 변수를 사용했다.
  2. 활성화 함수인 시그모이드 함수 $y = \sigma(z)$를 취해 결과 뉴런 $y$를 구한다. 이 결과로 얼마나 많은 $y$가 활성화되는지 확인할 수 있다.
- 순방향 신경망의 핵심은 이런 과정을 반복적으로 취해 이 두 단계로 이루어진 간단한 과정을 여러 번 적용하는 것이다.
  → **많은 층을 쌓아서 다층 신경망을 구성하는 것**

# 순방향 신경망



- 만약 한 층을 더 추가하면 어떤 단계를 거치게 될까?
  1. 입력값 $x$에 $z^1 = W^1x + b^1$을 구하자.
  2. 중간 결과 $z^1$으로부터 $y = W^2z^1 + b^2$을 구해서 출력값 $y$를 구하자.

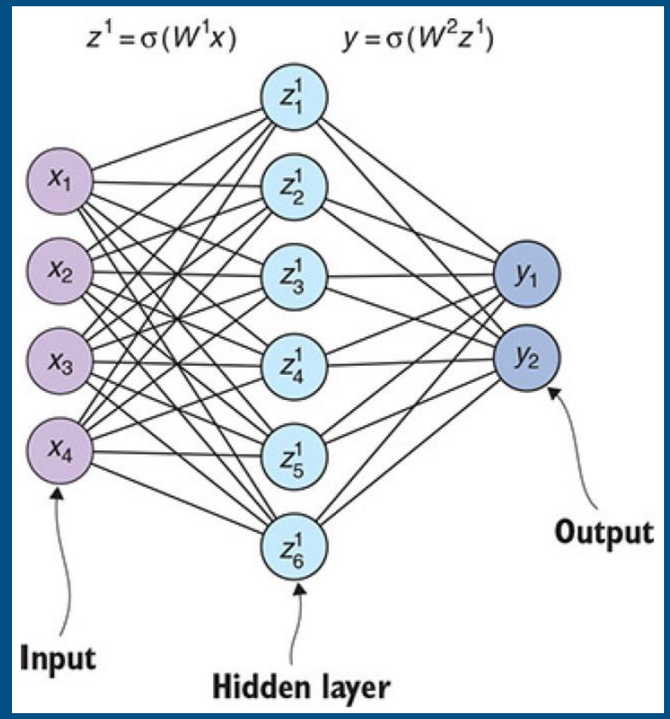

# 순방향 신경망



- **순방향 전달 (Forward Pass)** : 활성화 함수를 신경망의 모든 층에서 하나 혹은 여러 데이터에 적용하는 것 (순방향 : 입력 → 출력)

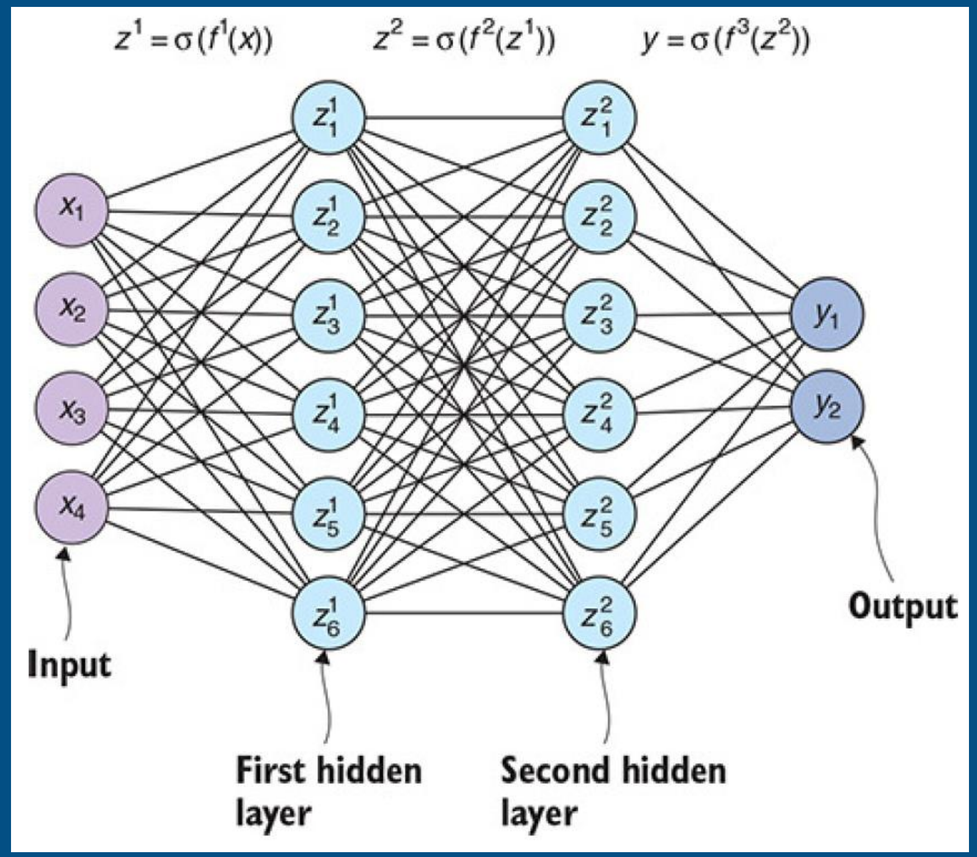

# 순방향 신경망



- 지금까지 이야기했던 모든 개념을 정리해보자.
  - **순차 신경망**은 특징(혹은 입력 뉴런) $x$를 예측값(혹은 출력 뉴런) $y$에 대응시키는 과정이다. 이 과정은 순서대로 하나씩 함수층을 쌓아가면서 이루어진다.
  - **층**은 입력값에 변화를 가해 출력값을 도출하는 곳이다. 특정 크기의 데이터에 대한 층의 출력을 구하는 한 차례의 처리를 **순방향 전달**이라고 한다. 마찬가지로 순차 신경망에서 순방향 전달은 입력에서 출력 방향으로, 즉 순방향으로 각 층의 출력값을 순서대로 구하는 것이다.
  - **시그모이드 함수**는 실수 뉴런 벡터를 사용해서 $[0,1]$의 범위에 대응시키는 방식으로 **활성화**시키는 활성화 함수다. 이 값이 1에 가까우면 활성화 상태라고 해석한다.

# 순방향 신경망



- 지금까지 이야기했던 모든 개념을 정리해보자.
  - 가중치 행렬 $W$와 편향치 $b$가 주어졌을 때 아핀 선형 변환 $Wx + b$는 층을 구성한다. 이런 종류의 층을 보통 **밀집층** 혹은 **완전 연결층**이라고 한다.
  - 구현에 따라 밀집층에는 활성화 함수가 포함되기도 하고 아니기도 하다. $\sigma(Wx + b)$를 아핀 선형 변환이 아닌 층으로 볼 수도 있다. 일반적으로 활성화 함수만을 층으로 간주한다. 결국 밀집층에 활성화 함수를 추가할 것인지 아닌지는 기능의 일부를 어떻게 분할하고 논리적인 단위로 그룹화할 것인지에 대한 약간 다른 견해일 뿐이다.
  - 순방향 신경망은 밀집층과 활성화 함수로 구성된 순차 신경망이다. 이런 구조를 **다층 퍼셉트론 (Multilayer Perceptron)** 혹은 짧게 **MLP**라고 부른다.

# 순방향 신경망



- 지금까지 이야기했던 모든 개념을 정리해보자.
  - 입력 뉴런이나 출력 뉴런이 아닌 모든 뉴런은 **은닉 유닛**이고, 입력 및 출력 뉴런은 **가시 유닛**이다. 여기에는 은닉 유닛은 신경망 안에, 가시 유닛은 바로 관측 가능한 곳에 있다는 개념이 깔려 있다. 마찬가지로 입력과 출력 사이의 층은 **은닉층(Hidden Layer)**이라고 한다.  두 개 층 이상을 가지는 순차 신경망은 최소 1개 이상의 은닉층을 가진다.
- 많은 은닉층을 가진 거대한 신경망을 구축하려고 많은 층을 쌓은 경우를 **심층 신경망(Deep Neural Network)**이라고 하며,
  그래서 **딥러닝(Deep Learning)**이라는 이름이 붙었다.

# 손실 함수와 최적화



- **손실 함수(Loss Function)**란 무엇인가
  - 예측값의 적중률이 어느 정도 되는지를 수치화한 것
    (**목적 함수(Objective Function)**라고도 한다.)

$$\sum_i \text{Loss}(W, b, X_i, \hat{y}_i) = \sum_i \text{Loss}(y_i, \hat{y}_i)$$

  - 여기서 $\text{Loss}(y_i, \hat{y}_i) \geq 0$이고, Loss는 **미분 가능 함수**다.
  - 주어진 데이터에 대한 알고리즘의 파라미터가 얼마나 적합한지 평가한다.
  - 훈련 목표는 주어진 파라미터에 맞추는 좋은 전략을 찾아서 **손실을 최소화**하는 것이다.

# 손실 함수와 최적화



- **평균제곱오차 (Mean Square Error; MSE)**

$$\mathrm{MSE}(y, \hat{y}) = \frac{1}{2}\sum_{i=1}^{k}(y_i - \hat{y}_i)^2$$

  - 모든 관측된 예제에 대해 거리 제곱을 측정한 후 평균을 구함으로써 예측값이 실제 라벨에 얼마나 가까운지 측정하게 된다.

# 손실 함수와 최적화



- **평균제곱오차 (Mean Square Error; MSE)**
  - 평균제곱오차 손실 함수의 미분값

```python
import random
import numpy as np

class MSE:
  def __init__(self):
    pass

  @staticmethod
  def loss_function(predictions, labels):
    diff = predictions - labels
    return 0.5 * sum(diff * diff)[0]

  @staticmethod
  def loss_derivative(predictions, labels):
    return predictions - labels
```

# 손실 함수와 최적화



- 손실 함수에서의 최솟값 찾기
  - 함수를 미분해 특정 지점에서의 **기울기를 구한다**.

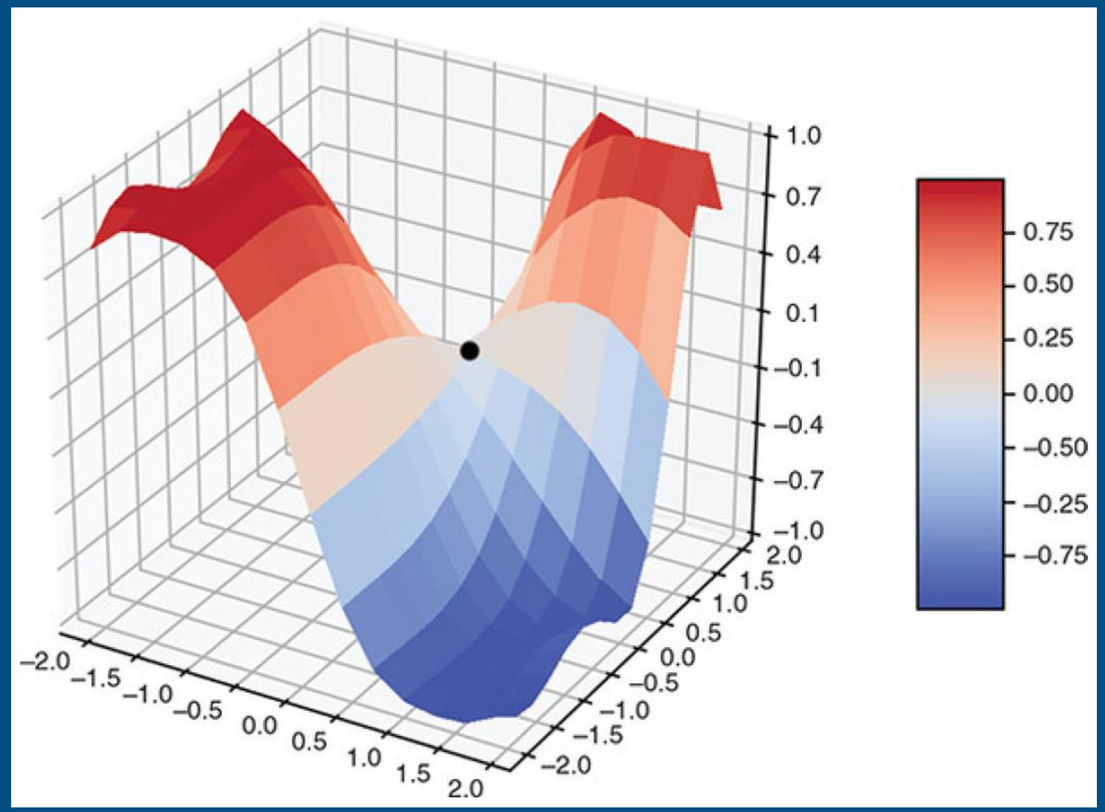

# 손실 함수와 최적화



- 최솟값을 찾는 **경사하강법 (Gradient Descent)** 알고리즘

1. 현재의 파라미터 집합 $W$에 대한 Loss의 기울기 $\Delta$를 구한다.
   (각 $W$에 대해 Loss의 미분값을 구함)
2. 이제 $W$에서 $\Delta$를 빼서 갱신한다.
   이 과정을 **기울기를 따라간다**고 한다.
   만약 $\Delta$가 가장 가파르게 상승하는 방향을
   가리킨다면 이 값을 뺌으로써
   가장 가파르게 하강할 것이기 때문이다.
3. $\Delta$가 0이 될 때까지 반복한다.

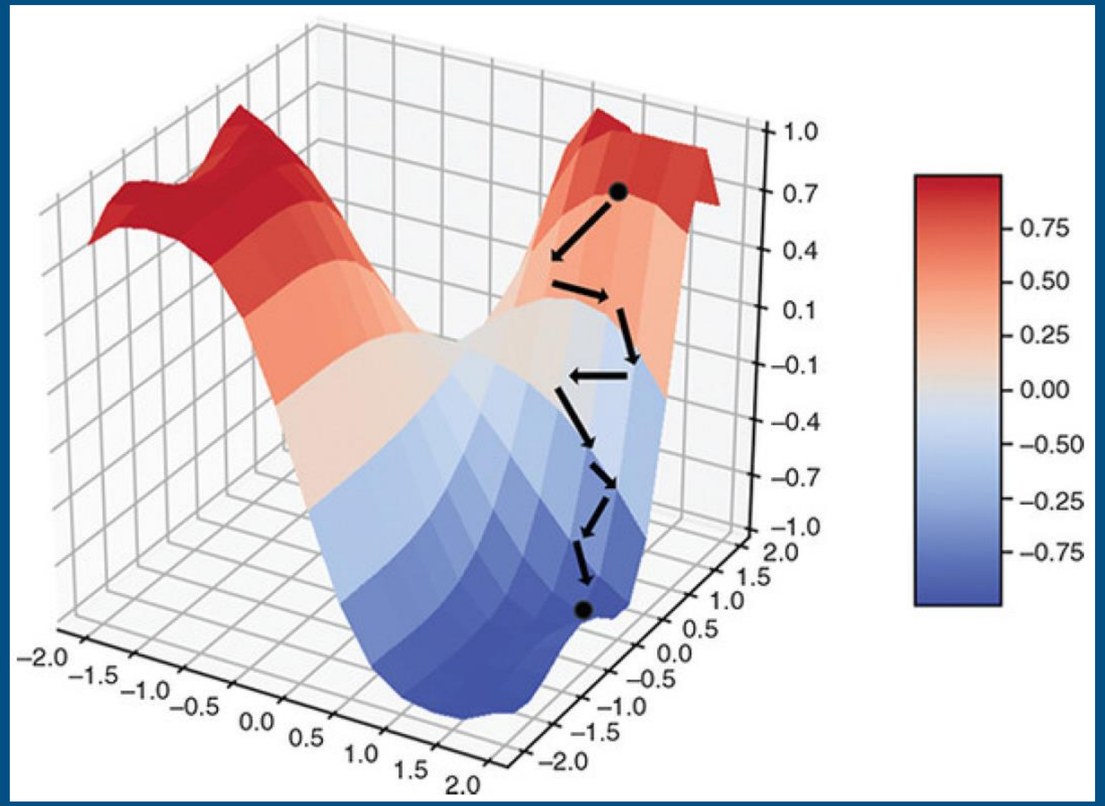

# 손실 함수와 최적화



- 최솟값을 찾는 **경사하강법 (Gradient Descent)** 알고리즘
  - 지역 최솟값과 전역 최솟값

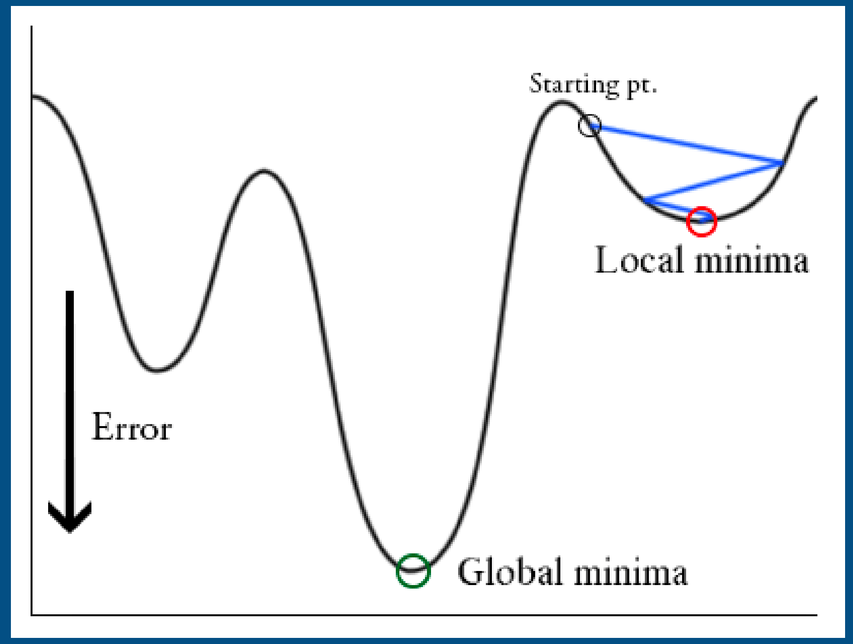


https://www.researchgate.net/figure/Gradient-Descent-Stuck-at-Local-Minima-18_fig4_338621083

# 손실 함수와 최적화



- 최솟값을 찾는 **경사하강법 (Gradient Descent)** 알고리즘
  - 모든 파라미터의 기울기를 살펴보려면 훈련 데이터셋의 모든 샘플에 대해 미분을 구하고 집계해야 한다. 모든 샘플을 다루기란 실질적으로 불가능하다.
    → **확률적 경사하강법**의 등장!

# 손실 함수와 최적화



- **확률적 경사하강법 (Stochastic Gradient Descent, SGD)**
  - 훈련 데이터 셋에서 샘플 데이터의 일부를 가져온다. → **미니배치(Mini-Batch)**
  - 각 미니배치는 일정한 길이를 갖는다. → **미니배치 크기**
  - 배치에서 사용한 각 층 및 샘플에 대해 기울기를 계산하고
    파라미터별로 다음과 같은 **갱신 규칙(= 최적화기(Optimizer))**을 적용할 수 있다.

$$W^i \leftarrow W^i - \alpha \sum_{j=1}^{k} \Delta_j W^i$$

$$b^i \leftarrow b^i - \alpha \sum_{j=1}^{k} \Delta_j b^i$$

  - 여기서 $\alpha > 0$은 **학습률(Learning Rate)**로 전반적인 신경망 훈련 정도를 나타낸다.

# 손실 함수와 최적화



- **확률적 경사하강법 (Stochastic Gradient Descent, SGD)**
  - 학습률의 중요성

repeat until convergence {

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$$

(for $j = 1$ and $j = 0$)

}

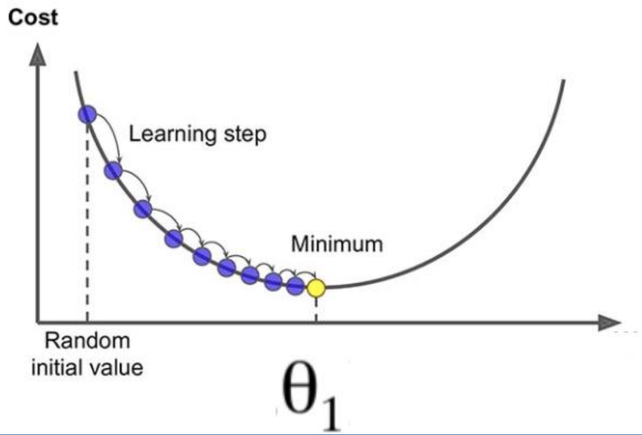


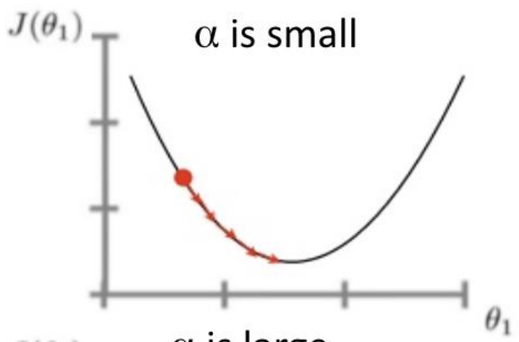


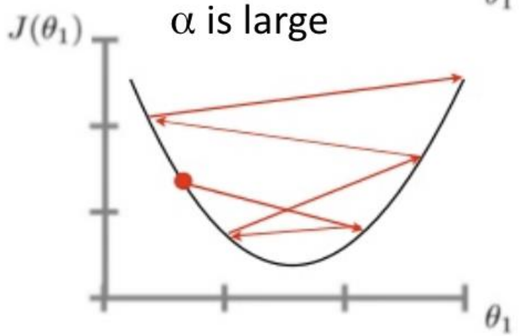


https://www.kdnuggets.com/2020/05/5-concepts-gradient-descent-cost-function.html

# 손실 함수와 최적화



- **확률적 경사하강법 (Stochastic Gradient Descent, SGD)**
  - 일반 경사하강법과 확률적 경사하강법의 차이

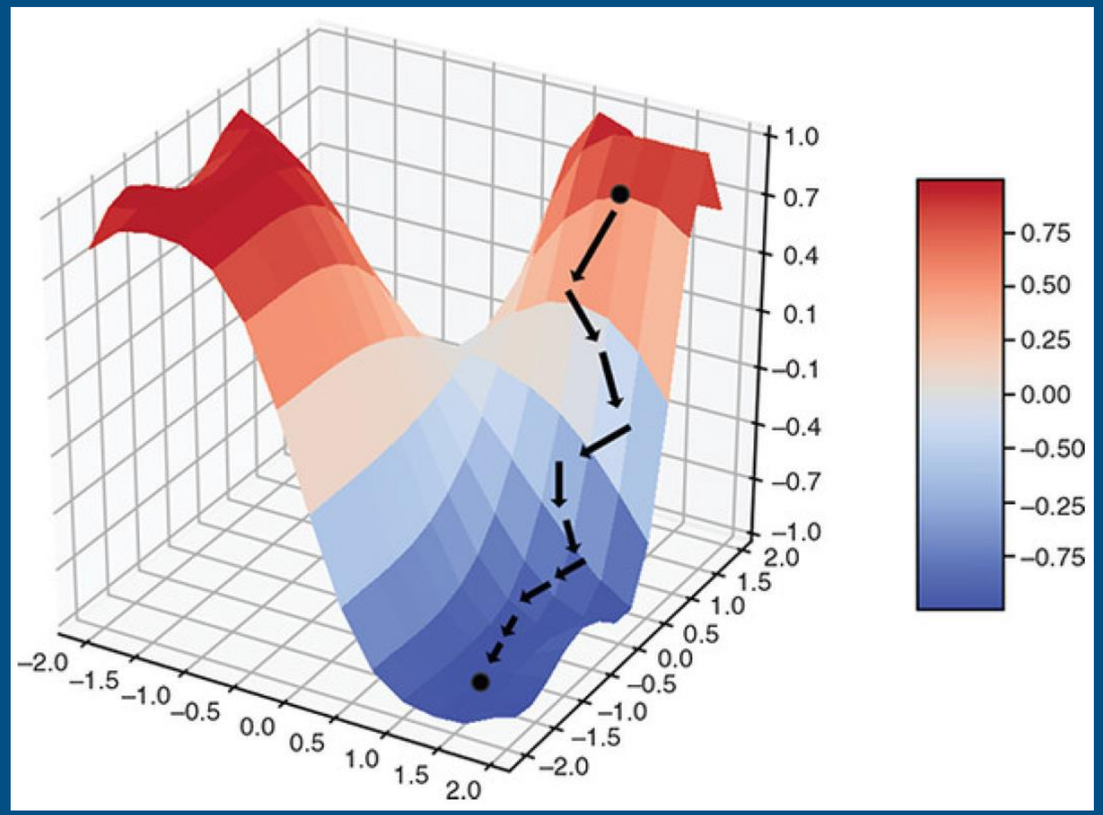

# 손실 함수와 최적화



- 신경망에 기울기를 역으로 전파하기
  - 역전파(Backpropagation) 알고리즘 = 기울기를 구하는 알고리즘

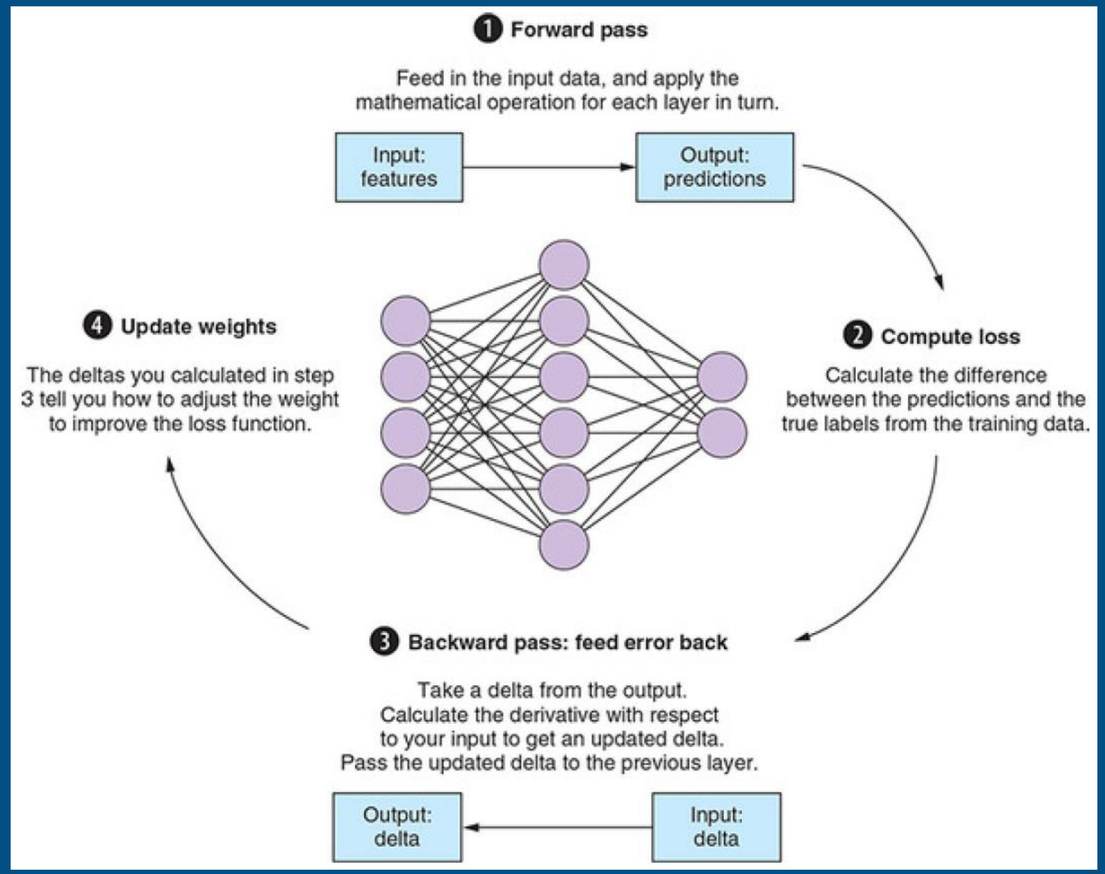

# 손실 함수와 최적화



- 신경망 훈련의 전체 흐름

1. **훈련 데이터를 순방향으로 전달한다.** 이 단계에서 입력 데이터 샘플 $x$를 신경망에 통과시켜 다음과 같이 예측값에 도달하도록 해야 한다.
   a. 아핀 선형 함수 $Wx + b$를 구한다.
   b. 결과에 시그모이드 함수 $\sigma(x)$를 적용한다. 이때 계산 단계에서의 $x$는 이전 단계의 출력값을 의미한다.
   c. 이 두 단계를 출력층에 도달할 때까지 반복한다.
      이 예시에서는 두 개 층을 사용했지만 실제 층수는 얼마가 되든 상관없다.
2. **손실 함수를 평가한다.**
   이 단계에서는 샘플 $x$의 라벨 $y$와 예측값 $\hat{y}$간의 손실값을 구하는 식으로 이 둘을 비교한다.

# 손실 함수와 최적화



- 신경망 훈련의 전체 흐름

3. **오차항을 역으로 전파한다.** 이 단계에서는 손실값을 신경망에 역으로 전달한다.
   층 방향으로 미분을 구하는 방식으로 이를 실행하며 연쇄법칙으로 가능하다.
   순방향 전달을 통해 입력 데이터를 신경망에서 한 방향으로 전달하는 동안
   역방향 전달을 통해 오차항을 반대 방향으로 전달한다.

   a. 오차항 Δ는 순방향 전달의 역순으로 전파한다.
   b. Δ의 초깃값으로 사용할 손실 함수의 미분(함수 형태)을 구한다.
      순방향 전달 과정에서는 전파되는 오차항을 Δ라고 부른다는 것을 다시 한 번 확인해서 틀리지 않도록 하자.
   c. 입력값에 대한 시그모이드 함수의 미분값을 구한다. 이는 간단히 $\sigma \cdot (1-\sigma)$로 나타낸다.
      다음 층으로 Δ를 전달하려면 $\sigma(1-\sigma) \cdot \Delta$ 식으로 요소 간의 곱을 구하면 된다.
   d. 그 결과 $x$에 대한 아핀 선형 변환 $Wx+b$의 미분값이 간단히 $W$로 나온다. Δ를 전달하려면 $W^T \cdot \Delta$를 구한다.
   e. 신경망의 첫 층에 도달할 때까지의 c와 d 두 단계를 반복한다.

# 손실 함수와 최적화



- 신경망 훈련의 전체 흐름

4. **1차 미분 정보로 가중치를 갱신한다.** 첫 단계에서는
   신경망 파라미터(가중치와 편향치) 갱신 과정에서 구해진 변화량을 사용한다.
   a. 시그모이드 함수에는 파라미터가 없으므로 여기서는 따로 해야 할 일이 없다.
   b. 각 층의 편향치에 도달하는 갱신된 $\Delta b$의 값은 간단히 $\Delta$다.
   c. 각 층의 가중치에 대한 갱신된 $\Delta W$의 값은 $\Delta \cdot x^T$이다.
      (변화량을 곱하기 전에 $x$를 전치해주어야 한다.)
   d. 한편 $x$에는 단일 데이터를 쓴다. 하지만 여기서 이야기한 모든 내용은 미니배치로 전달된다.
      만약 $x$가 샘플의 미니배치라면($x$는 모든 열이 입력 벡터인 행렬이다) 순방향과 역방향 전달에서의 계산은
      완전히 동일해 보일 것이다.

# Python을 활용한 신경망 훈련



- 순방향 신경망을 Python으로 구현할 때의 클래스 다이어그램

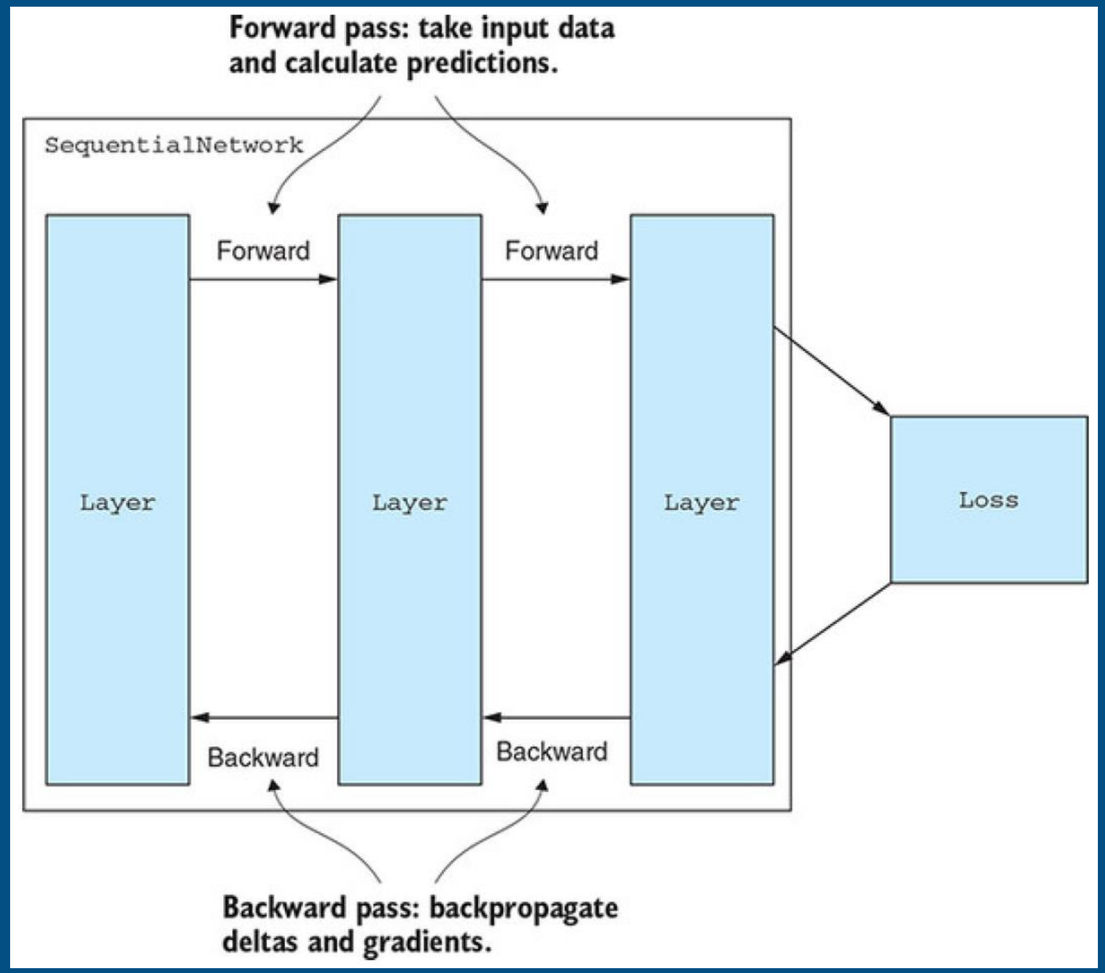

# Python을 활용한 신경망 훈련



- Python에서의 신경망층
  - 기본 층 구현

```python
import numpy as np

class Layer:
  def __init__(self):
    self.params = []

    self.previous = None
    self.next = None

    self.input_data = None
    self.output_data = None

    self.input_delta = None
    self.output_delta = None
```

# Python을 활용한 신경망 훈련



- Python에서의 신경망층
  - 층에 선제층과 후속층 연결

```
def connect(self, layer):
  self.previous = layer
  layer.next = self
```

# Python을 활용한 신경망 훈련



- Python에서의 신경망층
  - 순차 신경망의 층에서의 순방향 및 역방향 전달

```python
def forward(self):
  raise NotImplementedError

def get_forward_input(self):
  if self.previous is not None:
    return self.previous.output_data
  else:
    return self.input_data

def backward(self):
  raise NotImplementedError

def get_backward_input(self):
  if self.next is not None:
    return self.next.output_delta
  else:
    return self.input_delta

def clear_deltas(self):
  pass

def update_params(self, learning_rate):
  pass

def describe(self):
  raise NotImplementedError
```

# Python을 활용한 신경망 훈련



- Python에서의 활성화층
  - 시그모이드 함수의 미분 구현

```
def sigmoid_prime_double(x):
  return sigmoid_double(x) * (1 - sigmoid_double(x))

def sigmoid_prime(x):
  return np.vectorize(sigmoid_prime_double)(z)
```

# Python을 활용한 신경망 훈련



- Python에서의 활성화층
  - 시그모이드 활성화층

```python
class ActivationLayer(Layer):
  def __init__(self, input_dim):
    super(ActivationLayer, self).__init__()

    self.input_dim = input_dim
    self.output_dim = input_dim

  def forward(self):
    data = self.get_forward_input()
    self.output_data = sigmoid(data)

  def backward(self):
    delta = self.get_backward_input()
    data = self.get_forward_input()
    self.output_delta = delta * sigmoid_prime(data)

  def describe(self):
    print("|-- " + self.__class__.__name__)
    print("  |-- dimensions: ({},{})"
          .format(self.input_dim, self.output_dim))
```

# Python을 활용한 신경망 훈련



- Python에서의 활성화층
  - 순방향 신경망의 구성 요소로 Python에서의 밀집층

```python
class DenseLayer(Layer):
  def __init__(self, input_dim, output_dim):
    super(DenseLayer, self).__init__()

    self.input_dim = input_dim
    self.output_dim = output_dim

    self.weight = np.random.randn(output_dim, input_dim)
    self.bias = np.random.randn(output_dim, 1)

    self.params = [self.weight, self.bias]

    self.delta_w = np.zeros(self.weight.shape)
    self.delta_b = np.zeros(self.bias.shape)
```

# Python을 활용한 신경망 훈련



- Python에서의 활성화층
  - 밀집층의 순방향 전달

```python
def forward(self):
  data = self.get_forward_input()
  self.output_data = np.dot(self.weight, data) + self.bias
```

# Python을 활용한 신경망 훈련



- Python에서의 활성화층
  - 밀집층의 역방향 전달

```python
def backward(self):
  data = self.get_forward_input()
  delta = self.get_backward_input()

  self.delta_b += delta
  self.delta_w += np.dot(delta, data.transpose())

  self.output_delta = np.dot(self.weight.transpose(), delta)
```

# Python을 활용한 신경망 훈련



- Python에서의 활성화층
  - 밀집층 가중치 갱신 메커니즘

```python
def update_param(self):
  self.weight -= rate * self.delta_w
  self.bias -= rate * self.delta_b

def clear_deltas(self):
  self.delta_w = np.zeros(self.weight.shape)
  self.delta_b = np.zeros(self.bias.shape)

def describe(self):
  print("|--- " + self.__class__.__name__)
  print("  |-- dimensions: ({},{})"
        .format(self.input_dim, self.output_dim))
```

# Python을 활용한 신경망 훈련



- Python으로 순차 신경망 만들기
  - 순차 신경망 초기화

```
class SequentialNetwork:
  def __init__(self, loss=None):
    print("Initialize Network...")
    self.layers = []
    if loss is None:
      self.loss = MSE()
```

# Python을 활용한 신경망 훈련



- Python으로 순차 신경망 만들기
  - 순차적으로 층 추가

```
def add(self, layer):
  self.layers.append(layer)
  layer.describe()
  if len(self.layers) > 1
    self.layers[-1].connect(self.layers[-2])
```

# Python을 활용한 신경망 훈련



- Python으로 순차 신경망 만들기
  - 순차 신경망의 `train()` 메서드

```
def train(self, training_data, epochs, mini_batch_size,
          learning_rate, test_data=None):
  n = len(training_data)
  for epoch in range(epochs):
    random.shuffle(training_data)
    mini_batches = [
      training_data[k:k + mini_batch_size] for
      k in range(0, n, mini_batch_size)
    ]
    for mini_batch in mini_batches:
      self.train_batch(mini_batch, learning_rate)
    if test_data:
      n_test = len(test_data)
      print("Epoch {0}: {1} / {2}"
            .format(epoch, self.evaluate(test_data), n_test))
    else:
      print("Epoch {0} complete".format(epoch))
```

# Python을 활용한 신경망 훈련



- Python으로 순차 신경망 만들기
  - 신경망에서 규칙 및 순방향 전달과 역방향 전달 갱신하기

```python
def update(self, mini_batch, learning_rate):
  learning_rate = learning_rate / len(mini_batch)
  for layer in self.layers:
    layer.update_params(learning_rate)
  for layer in self.layers:
    layer.clear_deltas()

def forward_backward(self, mini_batch):
  for x, y in mini_batch:
    self.layers[0].input_data = x
    for layer in self.layers:
      layer.forward()
    self.layers[-1].input_delta = \
      self.loss.loss_derivative(self.layers[-1].output_data, y)
    for layer in reversed(self.layers):
      layer.backward()
```

# Python을 활용한 신경망 훈련



- Python으로 순차 신경망 만들기
  - 평가

```python
def single_forward(self, x):
  self.layers[0].input_data = x
  for layer in self.layers:
    layer.forward()
  return self.layers[-1].output_data

def evaluate(self, test_data):
  test_results = [(
    np.argmax(self.single_forward(x)),
    np.argmax(y)
  ) for (x, y) in test_data]
  return sum(int(x == y) for (x, y) in test_results)
```

# Python을 활용한 신경망 훈련



- 신경망으로 손글씨 숫자 분류하기
  - 신경망 인스턴스화

```python
from dlgo.nn import load_mnist
from dlgo.nn import network
from dlgo.nn.layers import DenseLayer, ActivationLayer

training_data, test_data = load_mnist.load_data()

net = network.SequentialNetwork()

net.add(DenseLayer(784, 392))
net.add(ActivationLayer(392))
net.add(DenseLayer(392, 196))
net.add(ActivationLayer(196))
net.add(DenseLayer(196, 10))
net.add(ActivationLayer(10))
```

# Python을 활용한 신경망 훈련



- 신경망으로 손글씨 숫자 분류하기
  - 훈련 데이터를 적용한 신경망 인스턴스 실행

```
net.train(training_data, epochs=10, mini_batch_size=10,
          learning_rate=3.0, test_data=test_data)
```

감사합니다!

스터디 듣느라 고생 많았습니다.